

Classificação Precoce de Campanhas Coordenadas em Redes Sociais com Características de Grafos Parciais

Gabriel de Santana Santos (RA 10420595), Gabriel Erick Mendes (RA 10420391),
Matheus Teles Magalhães (RA 10427410)

Faculdade de Computação e Informática - Universidade Presbiteriana Mackenzie
São Paulo - SP - Brasil

{10420595,10420391,10427410}@mackenzista.com.br

Abstract. This paper investigates early classification of coordinated social media campaigns from partial interaction graphs. The public Large Engagement Networks dataset is processed incrementally and reconstructed at ten observation fractions based on time and stored edges. After removing one exact duplicate, 103 local graphs produced 2,060 partial states. Exploratory results reveal a strong size imbalance: campaigns have a median of 506 users, while non-campaigns have 3,227. The next stage will compare a size-only baseline with Logistic Regression and Random Forest models to verify whether structural and temporal features provide information beyond this dataset bias.

Resumo. Este artigo investiga a classificação precoce de campanhas coordenadas a partir de grafos parciais de interação. O conjunto público Large Engagement Networks foi lido de forma incremental e reconstruído em dez frações de observação por tempo e por arestas armazenadas. Após retirar uma duplicata exata, 103 grafos locais produziram 2.060 estados parciais. A análise exploratória revelou forte diferença de tamanho: campanhas possuem mediana de 506 usuários e não campanhas, 3.227. A próxima etapa comparará um modelo que usa apenas tamanho com Regressão Logística e Random Forest, verificando se características estruturais e temporais acrescentam informação além desse viés.

1. Introdução

1.1. Contextualização

Redes sociais permitem que assuntos alcancem grande visibilidade em pouco tempo. Parte dessa disseminação ocorre de forma espontânea, enquanto outra parte pode ser amplificada por contas que agem de maneira coordenada. Essas interações podem ser representadas como grafos direcionados: os usuários são os vértices e retuítes, respostas e citações formam as arestas.

Este trabalho utiliza o Large Engagement Networks (LEN), conjunto de redes de engajamento rotuladas como campanhas e não campanhas [Gopalakrishnan et al. 2025]. Diferentemente da classificação do grafo completo, o projeto analisa estados formados somente pelas interações observadas até diferentes frações da evolução da rede.

1.2. Justificativa e motivação

A classificação baseada na rede completa ocorre quando grande parte da atividade já aconteceu. O uso de grafos parciais permite estudar se existem sinais úteis nas fases iniciais e evita fornecer ao modelo propriedades que só estariam disponíveis no futuro. Essa antecipação é relevante para apoiar análises de circulação de informações, mas aumenta a incerteza porque há menos evidências disponíveis [Varol et al. 2017].

Antes de empregar arquiteturas mais complexas, são necessários modelos simples e interpretáveis. Eles criam uma referência de desempenho e ajudam a verificar se a classificação aprende padrões de coordenação ou apenas diferenças de escala. O projeto também se relaciona ao ODS 16, por tratar de transparência e integridade dos ambientes digitais, sem propor acusação automática de pessoas ou remoção de conteúdo.

1.3. Objetivo

O objetivo é desenvolver e comparar modelos de classificação supervisionada que usem características estruturais e temporais de grafos parciais do LEN para distinguir campanhas coordenadas de tendências rotuladas como não campanhas. A comparação será feita em diferentes frações observadas, sem usar informações de estados posteriores.

1.4. Contribuições esperadas

Espera-se produzir uma tabela reproduzível de estados parciais, comparar um modelo que usa somente o tamanho da rede com Regressão Logística e Random Forest, medir o desempenho ao longo da evolução observada e identificar limitações dos dados. A Regressão Logística foi escolhida pela interpretação direta dos coeficientes; a Random Forest permite relações não lineares e interações entre medidas. O XGBoost, citado na proposta inicial, foi adiado até que a divisão da pequena amostra seja estabilizada, evitando ampliar o experimento sem evidência de benefício.

A proposta inicial foi refinada para avaliar grafos parciais, separar os dados por tópico e usar um baseline de tamanho, controlando o principal viés observado na análise.

2. Fundamentação teórica e trabalhos relacionados

2.1. Grafos parciais e classificação supervisionada

Um grafo direcionado $G=(V,E)$ representa usuários em V e interações em E . Medidas como grau, densidade, reciprocidade, componentes e modularidade resumem diferentes aspectos da estrutura [Newman 2010]. A modularidade compara a concentração de arestas dentro e entre grupos, sendo uma medida útil para descrever comunidades [Blondel et al. 2008].

Neste projeto, um estado parcial contém somente os nós que já participaram de uma interação e as arestas cujo timestamp está dentro do limite observado. São usadas duas formas de corte: fração da duração total e fração das arestas armazenadas. Elas não são equivalentes, pois a atividade não ocorre em ritmo constante. Essa representação segue a ideia de redes temporais, nas quais a ordem das relações faz parte do problema [Holme e Saramäki 2012].

2.2. Trabalhos relacionados

Ferrara et al. [2016] estudaram a identificação de campanhas promovidas a partir de características de usuários e difusão. Varol et al. [2017] avançaram para a detecção antecipada e mostraram que a importância das características muda conforme novas evidências aparecem. Esses trabalhos motivam a avaliação por frações, em vez de uma única classificação após o encerramento da atividade.

Pacheco et al. [2021] construíram redes a partir de traços compartilhados, como retuítes, hashtags, imagens e atividade temporal, para revelar grupos potencialmente coordenados. A solução mostra que a coordenação pode ser estudada pela relação entre contas e comportamentos, sem depender apenas do conteúdo individual.

Gopalakrishnan et al. [2025] apresentaram o LEN, com 314 redes de engajamento, sendo 179 campanhas e 135 não campanhas. O LEN-small contém as 100 menores redes. Os autores compararam descritores espectrais e redes neurais em grafos completos. O presente projeto usa a mesma base em outra pergunta: quanto da rede precisa ser observado para que a classificação se torne possível sem depender somente do tamanho final?

Modelos de GNN não serão usados nesta etapa. O LEN-small possui aproximadamente 100 grafos independentes, e os vários estados de um mesmo tópico não formam novas amostras independentes. Começar com modelos tabulares reduz a complexidade e permite verificar o protocolo antes de uma eventual extensão com GraphSAGE [Hamilton et al. 2017] ou modelos temporais [Rossi et al. 2020].

3. Metodologia e resultados esperados

3.1. Dataset

O LEN é um dataset público construído a partir de tendências do Twitter na Turquia. Campanhas foram associadas a ataques de astroturfing efêmero detectados entre março e maio de 2023. Não campanhas foram selecionadas manualmente entre notícias, esportes, festivais e outros acontecimentos considerados provavelmente orgânicos [Gopalakrishnan et al. 2025].

Cada JSON contém um grafo direcionado. As arestas possuem origem, destino, timestamp e Interaction_Count. O LEN mantém somente a interação mais recente de cada par ordenado; por isso, a reconstrução descreve a evolução das arestas retidas, não o fluxo completo do Twitter. Vetores de 772 posições nos nós e 776 nas arestas não entram no primeiro baseline, pois sua disponibilidade em cada instante ainda não foi demonstrada.

3.2. Preparação e análise exploratória

Os arquivos são processados de forma incremental com ijson. Valores NaN fora do padrão JSON são convertidos em nulos apenas no fluxo de leitura, sem modificar a base bruta. A preparação verifica duplicidades, endpoints ausentes, cobertura de timestamps e ordena as arestas cronologicamente.

Após retirar uma duplicata exata por arquivo de configuração, cada grafo é reconstruído em 10%, 20%, ..., 100% por duas modalidades: duração observada e quantidade de arestas observadas. Para cada estado são calculadas 57 medidas

estruturais e temporais. O atributo kcore fornecido no JSON não é usado, porque foi calculado no grafo completo e introduziria informação futura.

3.3. Protocolo de modelagem

Primeiro será confirmada a lista canônica dos 100 grafos do LEN-small. Em seguida, os tópicos serão separados em 75% para treino, 10% para validação e 15% para teste, com estratificação quando possível. A divisão ocorrerá antes da geração das janelas, mantendo todos os estados de um tópico no mesmo conjunto.

Serão comparados quatro grupos de atributos: somente tamanho; estrutura sem contagens brutas; somente tempo; e estrutura combinada com tempo. O tratamento de valores ausentes, a normalização e a seleção de medidas serão ajustados apenas com dados de treino. Cada modalidade e fração terá seu próprio treinamento.

A avaliação usará precisão, revocação, F1, ROC-AUC e PR-AUC. A relação entre precocidade e desempenho será apresentada por curvas de qualidade em função da fração observada. PR-AUC será mantida porque fornece uma leitura complementar quando a distribuição das classes ou o custo dos erros não for simétrico [Davis e Goadrich 2006].

3.4. Resultados esperados

Espera-se determinar se medidas estruturais e temporais acrescentam informação além do tamanho do grafo e identificar a menor fração em que o resultado se torna estável. Um resultado negativo também será relevante: se o modelo completo não superar o baseline de tamanho, a diferença observada deverá ser tratada como limitação do dataset.

4. Resultados parciais

4.1. Integridade e estados parciais

O pacote local contém 104 arquivos, enquanto a publicação descreve 100 no LEN-small. Foi identificado um par byte a byte idêntico. Após manter apenas uma cópia, restaram 103 grafos: 52 campanhas e 51 não campanhas. A Tabela 1 resume a amostra efetivamente analisada. Os três arquivos excedentes ainda serão confirmados antes da divisão final.

Tabela 1. Resumo da amostra local após a exclusão da duplicata

Item	Resultado
Grafos únicos locais	103
Campanhas	52
Não campanhas	51
Cobertura de timestamp nas arestas	100%
Estados parciais	2.060
Medidas por estado	57

Não foram encontrados IDs de usuários duplicados nem arestas apontando para usuários inexistentes. Os estados parciais são monotônicos: nenhum estágio posterior

perde nós ou arestas, e as duas modalidades chegam ao mesmo grafo em 100%. Existem 26 estados com uma única aresta; neles, quatro estatísticas de intervalo entre eventos são indefinidas e serão tratadas somente com regras ajustadas no treino.

4.2. Diferenças entre as classes

A principal diferença encontrada é a escala. As campanhas do pacote local são menores que as não campanhas, como mostra a Figura 1. Em 93,6% das comparações entre uma campanha e uma não campanha escolhidas ao acaso, a campanha possui menos usuários. Essa separação pode criar um atalho para o classificador.




Figura 1. Distribuição do número de usuários e arestas nos 103 grafos locais únicos.

Tabela 2. Medianas das principais medidas nos grafos completos

Medida	Campanhas	Não campanhas
Usuários	506	3.227
Arestas	1.078	3.769
Interações agrupadas	1.647	4.835
Duração (horas)	22,60	23,94
Reciprocidade	0,0311	0,0051
Parcela no maior componente	69,3%	72,5%

A densidade é maior nas campanhas, mas sua correlação de Spearman com o número de usuários é -0,98. Isso não indica causalidade: o denominador da densidade cresce aproximadamente com o quadrado do número de usuários. A densidade, portanto, não pode ser interpretada isoladamente como sinal de coordenação.

4.3. Evolução das redes

Foram gerados 2.060 estados, correspondentes a 103 grafos, duas modalidades e dez frações. Em 10% das arestas, a campanha mediana possui 73,5 usuários e 108,5 arestas. Em 10% do tempo, ela possui somente 24 usuários e 22,5 arestas. Assim, uma mesma fração numérica representa quantidades de informação diferentes nas duas modalidades.

A Figura 2 normaliza a quantidade de usuários pelo tamanho final de cada grafo. Em 10% das arestas, campanhas apresentam 12,9% dos usuários finais e não

campanhas, 12,1%. Em 30% do tempo, esses valores são 27,9% e 21,3%. As curvas próximas reforçam que boa parte da separação absoluta vem do tamanho final, não apenas do ritmo de crescimento.




Figura 2. Crescimento mediano normalizado pelo total de usuários de cada grafo.

Como indício exploratório, em 10% das arestas a modularidade mediana foi 0,405 nas campanhas e 0,835 nas não campanhas. Essa diferença ainda precisa ser controlada pelo tamanho e não representa desempenho de classificação. Até o momento, nenhum modelo foi treinado e não existem resultados próprios de acurácia, precisão, revocação ou F1.

4.4. Implementação e reprodutibilidade

O código implementa leitura incremental, criação dos grafos parciais e extração das características. Sete testes automatizados verificam o leitor, a reconstrução temporal, as medidas e a exportação das tabelas. Os notebooks foram executados integralmente e mantêm seus resultados salvos.

O repositório público da disciplina é:

https://github.com/Mendes1801/proj_IA7N_deteccao_de_campanhas_em_grafos. Ele contém o artigo, a descrição do dataset, as tabelas processadas, os notebooks, o código-fonte, os testes e o histórico das alterações. Os JSONs brutos, com cerca de 5,4 GB, são obtidos na página oficial do LEN e não são duplicados no GitHub.

4.5. Aspectos éticos e responsabilidade no uso da IA

Um falso positivo pode associar uma mobilização legítima a comportamento coordenado; um falso negativo pode deixar uma campanha relevante sem sinalização. A solução deve ser usada como apoio à análise humana, nunca como mecanismo autônomo de punição, remoção de conteúdo ou atribuição de intenção.

Os rótulos são operacionais. Campaign indica que o LEN encontrou o padrão de ataque usado na construção da base; não significa que todos os usuários sejam inautênticos. Noncampaign foi atribuído a tendências consideradas provavelmente orgânicas e não comprova ausência total de coordenação [Gopalakrishnan et al. 2025].

Os dados representam tendências turcas coletadas em um período eleitoral. Resultados não devem ser generalizados automaticamente para outros países, idiomas e tipos de campanha. O projeto trabalha com medidas agregadas, não tenta reidentificar

peessoas e documenta os vieses de rótulo e tamanho. Essas medidas seguem a orientação de mapear riscos, limitações e supervisão humana durante o desenvolvimento [NIST 2023].

Referências

- Blondel, V. D., Guillaume, J.-L., Lambiotte, R. e Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008.
- Davis, J. e Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. In *Proceedings of the 23rd International Conference on Machine Learning*, p. 233-240.
- Ferrara, E., Varol, O., Menczer, F. e Flammini, A. (2016). Detection of promoted social media campaigns. *Proceedings of the International AAAI Conference on Web and Social Media*, 10(1), 563-566.
- Gopalakrishnan, A. A., Hossain, J., Elmas, T. e Sariyüce, A. E. (2025). Large Engagement Networks for classifying coordinated campaigns and organic Twitter trends. *Proceedings of the International AAAI Conference on Web and Social Media*, 19(1), 688-702.
- Hamilton, W. L., Ying, R. e Leskovec, J. (2017). Inductive representation learning on large graphs. *Advances in Neural Information Processing Systems*, 30.
- Holme, P. e Saramäki, J. (2012). Temporal networks. *Physics Reports*, 519(3), 97-125.
- National Institute of Standards and Technology (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1.
- Newman, M. E. J. (2010). *Networks: An Introduction*. Oxford University Press.
- Pacheco, D., Hui, P.-M., Torres-Lugo, C., Truong, B. T., Flammini, A. e Menczer, F. (2021). Uncovering coordinated networks on social media: methods and case studies. *Proceedings of the International AAAI Conference on Web and Social Media*, 15(1), 455-466.
- Rossi, E., Chamberlain, B., Frasca, F., Eynard, D., Monti, F. e Bronstein, M. (2020). Temporal Graph Networks for deep learning on dynamic graphs. *arXiv:2006.10637*.
- Varol, O., Ferrara, E., Menczer, F. e Flammini, A. (2017). Early detection of promoted campaigns on social media. *EPJ Data Science*, 6, 13.