

Classificação Precoce de Campanhas Coordenadas em Redes Sociais com Características de Grafos Parciais

Gabriel de Santana Santos (RA 10420595), Gabriel Erick Mendes (RA 10420391),
Matheus Teles Magalhães (RA 10427410)

Faculdade de Computação e Informática - Universidade Presbiteriana Mackenzie
São Paulo - SP - Brasil

{10420595,10420391,10427410}@mackenzista.com.br

Abstract. This paper investigates whether partial interaction graphs can support the early identification of coordinated campaigns. We analyze the local LEN-Small package, with 103 unique graphs after removing one duplicate. Partial graphs are observed from 20% to 100% of the stored edges. Preliminary results show differences in graph size, reciprocity, and clustering between campaigns and non-campaigns. The next stage will compare Logistic Regression and Random Forest. The main limitation is temporal: only the most recent interaction of each ordered user pair keeps a timestamp. Overall temporal coverage is 72.3% and falls to 45.6% in campaigns, so temporal conclusions are exploratory.

Resumo. Este artigo investiga se características de grafos parciais podem ajudar na identificação antecipada de campanhas coordenadas. Analisamos o pacote local do LEN-Small, com 103 grafos únicos após a retirada de uma duplicata. Os grafos são observados entre 20% e 100% das arestas armazenadas. Os resultados preliminares mostram diferenças de tamanho, reciprocidade e agrupamento entre campanhas e não campanhas. Na próxima etapa, serão comparadas Regressão Logística e Random Forest. A principal limitação é temporal: apenas a interação mais recente de cada par ordenado mantém um timestamp. A cobertura geral é de 72,3% e cai para 45,6% nas campanhas, por isso as conclusões temporais são exploratórias.

1. Introdução

1.1. Contextualização

Campanhas coordenadas usam várias contas para aumentar artificialmente a visibilidade de uma mensagem. Para estudá-las, representamos os usuários como nós e as interações, como retuítes, respostas e citações, como arestas.

Este trabalho usa o LEN-Small, um recorte reduzido do conjunto LEN. Em vez de analisar somente o grafo final, observamos estados parciais entre 20% e 100% das arestas armazenadas.

1.2. Justificativa

Identificar uma campanha apenas quando o tópico termina tem pouca utilidade para uma análise antecipada. Por isso, queremos verificar se sinais simples já aparecem enquanto a rede ainda está crescendo.

1.3. Motivação

O LEN-Small permite comparar campanhas conhecidas com tópicos considerados provavelmente orgânicos. Porém, as classes têm tamanhos diferentes e parte dos horários foi perdida. Isso exige cuidado para não confundir coordenação com tamanho da rede ou ausência de dados.

1.4. Objetivo

O objetivo é verificar se reciprocidade e agrupamento, calculados em grafos parciais, ajudam a diferenciar campanhas de não campanhas além do tamanho da rede. Na próxima etapa, a comparação será feita com Regressão Logística e Random Forest.

1.5. Contribuições esperadas

Esta etapa prepara os grafos parciais, descreve as diferenças entre as classes e mede a perda de timestamps. Também define os modelos e as métricas que serão usados na etapa de classificação.

2. Fundamentação teórica e trabalhos relacionados

2.1. Conceitos básicos

Um grafo representa relações entre elementos. Neste estudo, os usuários são os nós e as interações são as arestas. As duas medidas principais são a reciprocidade, que indica interações nos dois sentidos, e o agrupamento, que mostra se usuários próximos também interagem entre si [Newman 2010].

Um estado parcial contém apenas parte do grafo final. Ele pode ser criado pela duração observada ou pela quantidade de arestas armazenadas. Esses recortes podem ser diferentes porque a atividade não acontece em ritmo constante [Holme e Saramäki 2012].

2.2. Trabalhos relacionados

Ferrara et al. [2016] mostraram que características dos usuários e da difusão das mensagens ajudam a identificar campanhas promovidas.

Varol et al. [2017] estudaram a detecção antecipada e observaram que as características úteis mudam conforme novas interações aparecem. Esse resultado apoia a análise em vários pontos de observação.

Pacheco et al. [2021] criaram redes a partir de sinais compartilhados, como retuítes, hashtags e atividade temporal. O trabalho mostra que a coordenação pode aparecer nas relações entre contas.

3. Metodologia e resultados esperados

3.1. Dataset

O estudo usa o pacote local associado ao LEN-Small, um recorte reduzido do LEN. O artigo original descreve 100 grafos, mas o pacote local contém arquivos extras. Por isso, a lista definitiva será confirmada antes do treinamento.

Os dados foram coletados no Twitter, na Turquia, entre março e maio de 2023 [Gopalakrishnan et al. 2025]. Os autores classificaram os tópicos como campanhas artificiais de curta duração ou acontecimentos provavelmente orgânicos.

Cada arquivo JSON contém um grafo direcionado. As arestas registram origem, destino, o timestamp mais recente e o campo `Interaction_Count`, que informa quantas interações ocorreram entre o mesmo par de usuários.

3.2. Preparação e análise exploratória

Primeiro, verificamos arquivos duplicados, usuários ausentes e timestamps. Depois, cada grafo foi reconstruído pela duração observada e pela quantidade de arestas armazenadas.

Os estados parciais começam em 20% e seguem até 100%. Nenhum modelo foi treinado nesta etapa; os resultados apresentados são apenas descritivos.

3.3. Limitação dos timestamps

O LEN mantém apenas o timestamp da interação mais recente de cada par ordenado de usuários. Quando o mesmo par interage várias vezes, o `Interaction_Count` registra o total, mas os horários anteriores não estão disponíveis.

Na amostra local, o `Interaction_Count` soma 399.268 interações. Dessas, 288.540 possuem horário individual e 110.728 não podem ser colocadas na sequência original. A cobertura é de 72,3%, próxima dos 74% informados para a base.

Com os horários anteriores ausentes, uma relação repetida aparece somente no momento da última interação armazenada. Isso pode alterar os grafos parciais e o ponto em que um sinal surge. Como não criamos horários artificiais, toda conclusão temporal será tratada como exploratória.

3.4. Modelos e avaliação

Os tópicos serão separados antes da criação dos estados parciais. Assim, versões do mesmo grafo não aparecem ao mesmo tempo nos dados de treino e de teste.

Serão comparados dois modelos. A Regressão Logística servirá como modelo simples e interpretável. A Random Forest será usada para representar relações que não sejam lineares.

A avaliação usará F1, recall, acurácia e matriz de confusão. O recall indica quantas campanhas reais foram encontradas, a acurácia mostra a proporção total de acertos, o F1 equilibra os acertos da classe positiva e a matriz de confusão separa os tipos de erro.

3.5. Resultados esperados

Esperamos verificar se reciprocidade e agrupamento acrescentam informação além do tamanho da rede. Se os modelos não melhorarem com essas medidas, esse resultado também será registrado. A perda de timestamps impede afirmar o momento exato em que uma campanha poderia ser detectada.

4. Resultados parciais

4.1. Integridade da amostra

A pasta local contém 104 arquivos. Um par era idêntico byte a byte; depois da exclusão, foram analisados 103 grafos: 52 campanhas e 51 não campanhas.

Tabela 1. Resumo da amostra local

Item	Resultado
Grafos locais analisados	103
Campanhas	52
Não campanhas	51
Interações registradas	399.268
Interações com timestamp individual	72,3%

Não foram encontrados usuários duplicados dentro dos grafos nem arestas apontando para usuários inexistentes. Os estados parciais também crescem de forma consistente até o grafo final.

4.2. Diferença de tamanho entre as classes

A diferença mais visível entre as classes é o tamanho. As campanhas locais têm menos usuários e arestas do que as não campanhas, como mostra a Figura 1. Um modelo pode usar essa diferença como atalho, sem aprender um padrão de coordenação.




Figura 1. Número de usuários e arestas por classe nos 103 grafos locais.

4.3. O que aparece nos grafos parciais

Os recortes foram montados pela duração observada e pela quantidade de arestas armazenadas. Como a atividade varia ao longo do tempo, uma mesma porcentagem pode representar quantidades diferentes de informação.

A Figura 2 mostra como o número de usuários se aproxima do total final. As classes seguem trajetórias parecidas, principalmente quando o recorte usa a quantidade de arestas. Portanto, o crescimento relativo sozinho pode não separar bem as classes.




Figura 2. Crescimento mediano dos usuários conforme mais arestas são observadas.

As Figuras 4 e 5 começam em 20% e mostram reciprocidade e agrupamento. Em todos os pontos observados, as medianas das campanhas são maiores que as das não campanhas.

Essa diferença é um resultado preliminar. Ela indica que as medidas estruturais podem ser úteis, mas ainda não mostra se os modelos conseguirão classificar os grafos corretamente.




Figura 4. Reciprocidade mediana entre 20% e 100% das arestas armazenadas.




Figura 5. Agrupamento mediano entre 20% e 100% das arestas armazenadas.

4.4. Perda de informação temporal

Cada aresta armazenada possui um timestamp, mas pode representar várias interações. Por isso, contar apenas as arestas faz parecer que há mais informação temporal do que realmente existe. Na amostra, 110.728 interações não possuem horário individual.

Tabela 2. Disponibilidade de horário individual por classe

Classe	Interações	Com horário	Sem horário	Cobertura
Campanhas	147.749	67.383	80.366	45,6%
Não campanhas	251.519	221.157	30.362	87,9%
Total	399.268	288.540	110.728	72,3%




Figura 3. Interações com e sem timestamp individual no LEN-Small local.

A perda é desigual. Apenas 45,6% das interações de campanhas possuem horário individual, contra 87,9% nas não campanhas. Assim, mais da metade da sequência temporal das campanhas não pode ser reconstruída.

Grafos maiores acumulam mais interações sem horário em números absolutos. Porém, dentro de cada classe, a porcentagem perdida muda pouco com o tamanho do grafo. Isso indica que o tamanho, sozinho, não explica a perda; a repetição de interações entre os mesmos pares também tem peso importante.

Não é possível medir o impacto exato dessa perda porque os horários descartados não estão disponíveis. Mesmo que um modelo apresente bons resultados, ele não provará que a campanha poderia ser reconhecida naquele momento da sequência real.

4.5. Limitações e uso responsável

Um falso positivo pode marcar uma mobilização legítima como campanha, enquanto um falso negativo pode deixar uma campanha sem sinalização. Por isso, os modelos devem servir apenas como apoio à análise humana.

Os rótulos Campaign e Noncampaign descrevem como a base foi montada, não a intenção de cada usuário. Além disso, os dados representam tendências turcas de um período eleitoral e não devem ser generalizados automaticamente para outros contextos.

O repositório público da disciplina, com o artigo, a descrição do dataset, os notebooks e os arquivos de análise, está disponível em:
https://github.com/Mendes1801/proj_IA7N_deteccao_de_campanhas_em_grafos.

Referências

- Ferrara, E., Varol, O., Menczer, F. e Flammini, A. (2016). Detection of promoted social media campaigns. *Proceedings of the International AAAI Conference on Web and Social Media*, 10(1), 563-566.
- Gopalakrishnan, A. A., Hossain, J., Elmas, T. e Sariyüce, A. E. (2025). Large Engagement Networks for classifying coordinated campaigns and organic Twitter trends. *Proceedings of the International AAAI Conference on Web and Social Media*, 19(1), 688-702.
- Holme, P. e Saramäki, J. (2012). Temporal networks. *Physics Reports*, 519(3), 97-125.
- Newman, M. E. J. (2010). *Networks: An Introduction*. Oxford University Press.
- Pacheco, D., Hui, P.-M., Torres-Lugo, C., Truong, B. T., Flammini, A. e Menczer, F. (2021). Uncovering coordinated networks on social media: methods and case studies. *Proceedings of the International AAAI Conference on Web and Social Media*, 15(1), 455-466.
- Varol, O., Ferrara, E., Menczer, F. e Flammini, A. (2017). Early detection of promoted campaigns on social media. *EPJ Data Science*, 6, 13.